강원대학교
첨단AI공학과

머신러닝2

- 지도학습 –

기계학습의 회귀분석

KNU 강원대학교

통계적 방법과 기계학습 방법의 차이

기계학습의 방법(지도학습)

- 다중 회귀분석(Regression)
- 로지스틱 회귀분석(Logistic Regression)
- 신경망(Atificial Neural Network)
- 서포트 백터 머신(Support Vector Machine)
- 의사결정나무(Decision Tree)
- 앙상블(Ensemble)
- K-근접 이웃기법(k-Nearest Neighbor)

로지스틱 회귀(Logistic Regression)

연속형 종속변수 경우?

- 독립변수를 바탕으로 종속변수를 예측함
- 강아지, 고양이와 같은 연속적이지 않은 범주형 변수를 어떻게 예측할까?

지점번호	홍보비용	직원수	지점성과	고객수	대출정도	유동인구	예금금액
1	40	15					2,000
2	50	20					3,500
3	30	14					4,000
4	60	22					3,500
5	70	30					4,900
6	60	24					3,100
7	30	16					4,200
8	60	20					2,300
9	20	14					6,000
10	80	32					5,000

로지스틱 회귀(Logistic Regression)

연속형 종속변수가 아닌 범주형 종속변수일 경우?

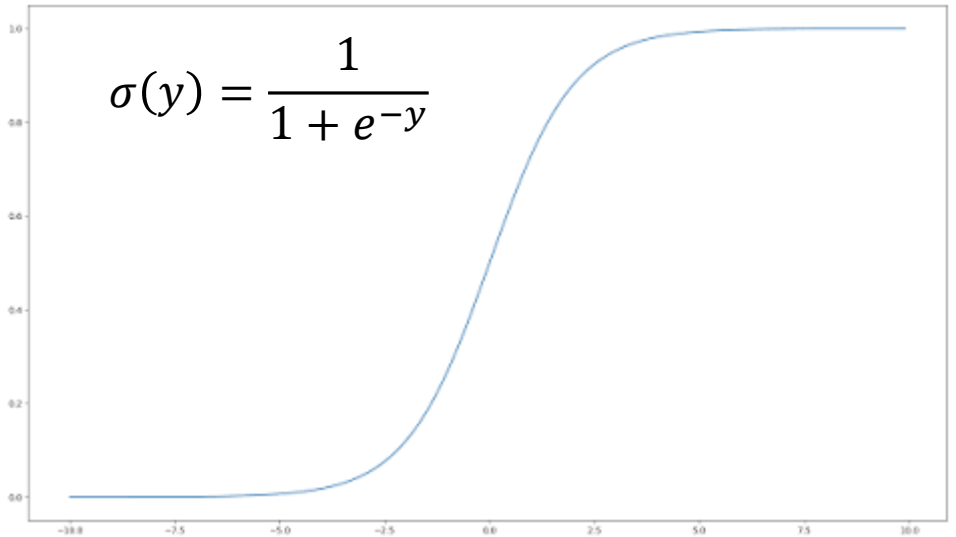
- 질병 진단(0 = 양성, 1 = 악성)
- 강아지, 고양이 판단

지점번호	홍보비용	직원수	지점성과	고객수	대출정도	유동인구	예금유지
1	40	15					0
2	50	20					1
3	30	14					1
4	60	22					1
5	70	30					1
6	60	24					1
7	30	16					0
8	60	20					1
9	20	14					0
10	80	32					1

로지스틱 회귀(Logistic Regression)

연속형 종속변수가 아닌 범주형 종속변수일 경우?

- **시그모이드 함수(Sigmoid Function) :** $0 < \sigma(y) < 1$ **사이의 값으로 구성되어 확률처럼 해석하기 좋음**
- **이진분류의 문제를 해결하기 위해 많이 사용**
- **활성화 함수(Activation Function)으로도 많이 사용됨(Forward → Loss → Backward → Optimizer)**



로지스틱 회귀(Logistic Regression)

연속형 종속변수가 아닌 범주형 종속변수일 경우?

- **로지스틱 회귀분석(Logistic Regression) : 로지스틱 회귀 모델은 시그모이드 함수라고도 알려진 로지스틱 함수를 사용하여 예측값을 확률에 매핑해 0과 1로 도출함**
- **질병 진단(0 = 양성, 1 = 악성)**
- **강아지, 고양이 판단**

$$y = \beta_0 + \beta_1 x_1 + \beta_n x_n + \cdots + \beta_n x_n$$ ⟹ **연속적인 수치정보를 제공함**

⇓

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$ ⟹ **이분류 문제로 데이터 값을 변경함**

로지스틱 회귀(Logistic Regression)

연속형 종속변수가 아닌 범주형 종속변수일 경우?

- **로지스틱 회귀분석(Logistic Regression) : 로지스틱 회귀 모델은 시그모이드 함수라고도 알려진 로지스틱 함수를 사용하여 예측값을 확률에 매핑해 0과 1로 도출함**
- **질병 진단(0 = 양성, 1 = 악성)**
- **강아지, 고양이 판단**

$$y = \beta_0 + \beta_1 x_1 + \beta_n x_n + \cdots + \beta_n x_n$$

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$

$$\beta_0 = -1,\ \beta_1 = 0.8,\ x_1 = 2, x_2 = 3$$

$$y = -1 + (0.8 * 2) - (0.5 * 3) = -0.9$$

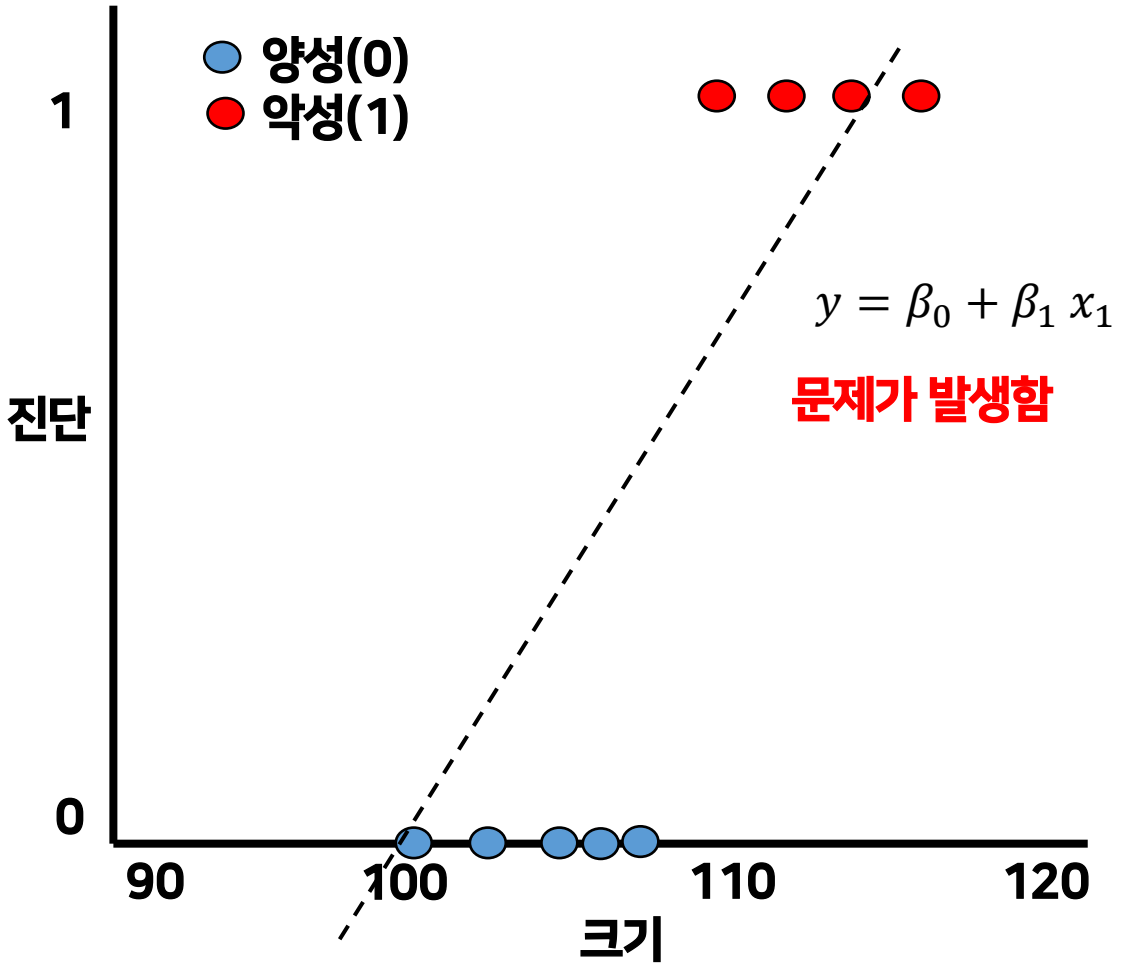
$$\sigma(y) = \frac{1}{1 + e^{-(-0.9)}} = 0.289$$

고양이 판단

로지스틱 회귀(Logistic Regression)

로지스틱 회귀

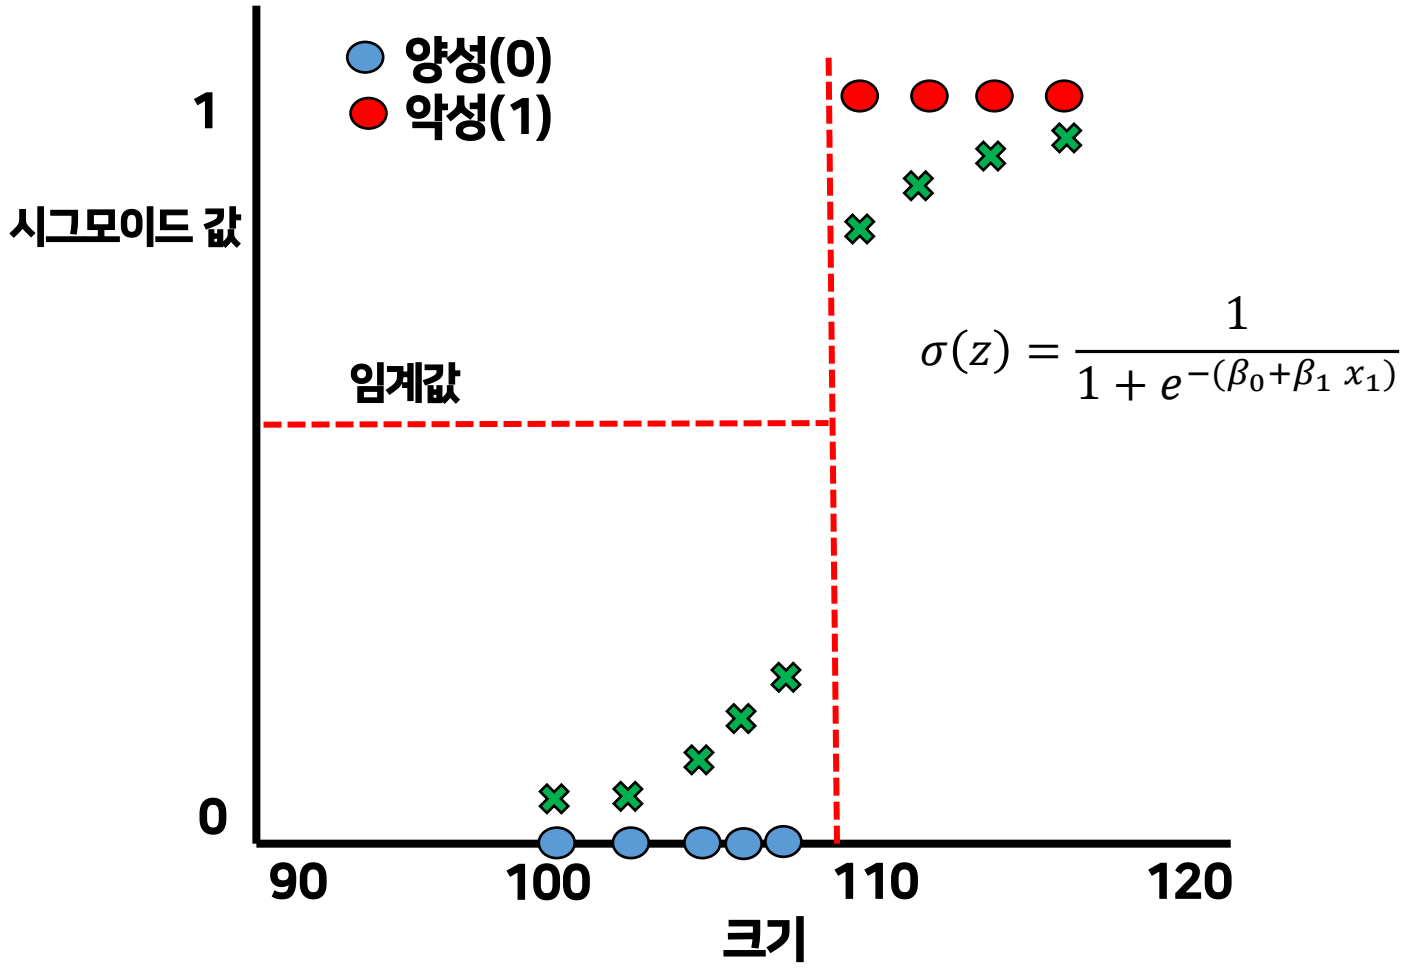
크기	진단
100	0
101	0
102	0
103	0
104	0
105	0
106	0
107	0
108	0
109	0
110	1
111	1
112	1
113	1
114	1



로지스틱 회귀(Logistic Regression)

로지스틱 회귀

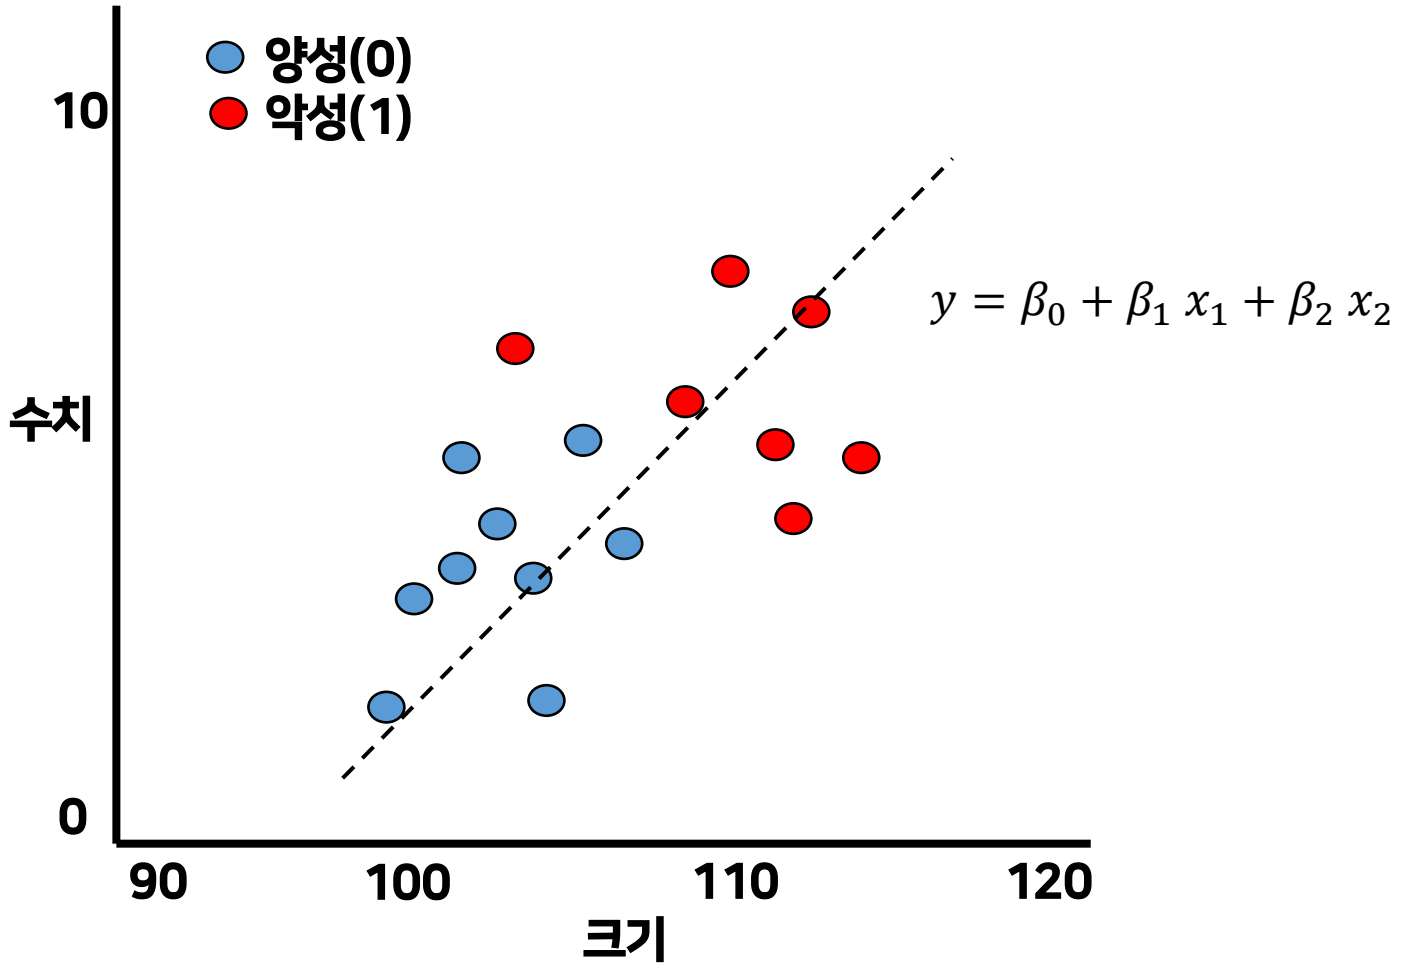
크기	예측확률	진단
100	0.005	0
101	0.007	0
102	0.009	0
103	0.01	0
104	0.02	0
105	0.05	0
106	0.1	0
107	0.4	0
108	0.5	0
109	0.6	0
110	0.65	1
111	0.7	1
112	0.75	1
113	0.8	1
114	0.9	1



로지스틱 회귀(Logistic Regression)

로지스틱 회귀

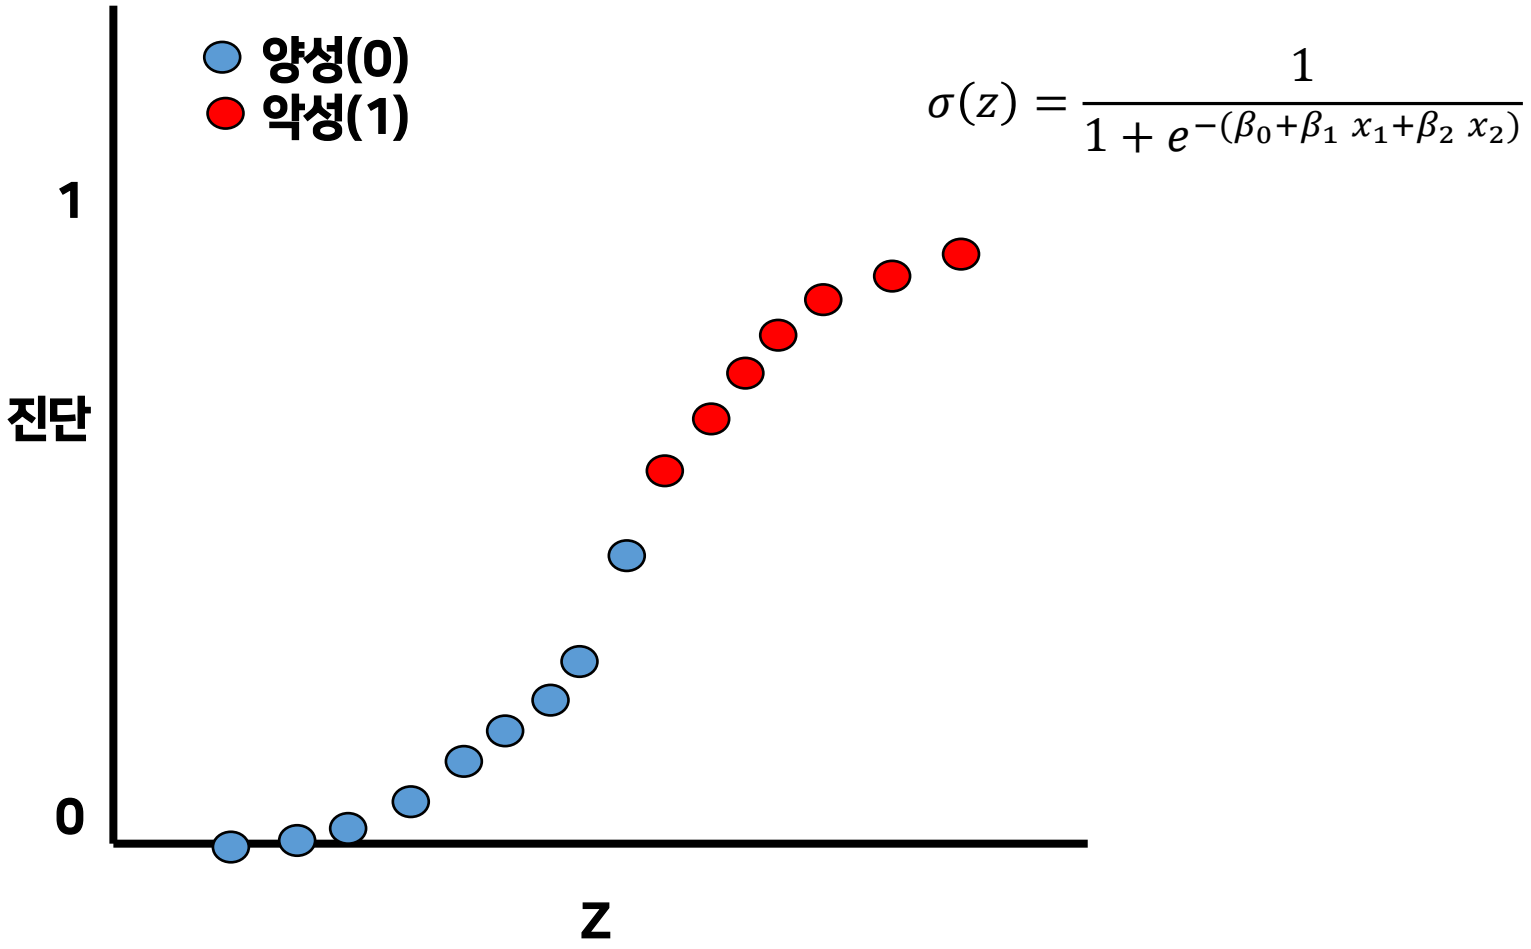
크기	수치	진단
100	5	0
101	6	0
102	7	0
103	4	0
104	5	0
105	7	0
106	4	0
107	6	0
108	8	0
109	5	0
110	8	1
111	5	1
112	7	1
113	9	1
114	8	1



로지스틱 회귀(Logistic Regression)

로지스틱 회귀

크기	수치	진단	예측확률
100	5	0	0.005
101	6	0	0.007
102	7	0	0.009
103	4	0	0.01
104	5	0	0.02
105	7	0	0.05
106	4	0	0.1
107	6	0	0.4
108	8	0	0.5
109	5	0	0.6
110	8	1	0.65
111	5	1	0.7
112	7	1	0.75
113	9	1	0.8
114	8	1	0.9



$$\sigma(z) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2)}}$$

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석

```
library(GGally)
library(skimr)
library(tidyverse)
library(tidymodels)
library(caret)

df <- read.csv("UniversalBank.csv", header = TRUE, na = ".“)
skim(df)

df$Personal.Loan <- ifelse(df$Personal.Loan == 1, "yes", "no")
df$Personal.Loan <- as.factor(df$Personal.Loan)

trainIndex <- createDataPartition(df$Personal.Loan, p = 0.8, list = FALSE)
train_data <- df[trainIndex,]
test_data <- df[-trainIndex,]
```

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석

```
result1=glm(train_data$Personal.Loan ~1, data= train_data, family = “binomial”)
result2=glm(train_data$Personal.Loan ~., data= train_data, family = “binomial”)

anova(result1, result2, test = "Chisq") #모델 전체가 유의한가?

summary(result2)

tidy_result <- tidy(result2)
tidy_result <- mutate_if(tidy_result, is.numeric, round, 3)

print(tidy_result)
```

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석

```
library(car)
library(broom)
library(dplyr)

#독립성 검정
durbinWatsonTest(result2)

# 다중공선성(변수의 중복성)
vif(result2)

# 다중공선성 위배 변수제거 후 다시 분석
result=glm(train_data$Personal.Loan ~., data= train_data, family = “binomial”)

# Cook's distance 계산 (glm에도 사용 가능)
influencePlot(result, id.method="identify")
```

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석

```
# 모델 저장
saveRDS(result, file = "logistic_model.rds")

# 모델 로드
Load <-readRDS("logistic_model.rds")

tidy_result <- tidy(Load)
tidy_result

tidy_result <- mutate_if(tidy_result, is.numeric, round, 3)
tidy_result
```

로지스틱 회귀(Logistic Regression)

모델검정

- 수치형 : RMSE, R-Squared(R^2)
- 범주형 : Accuracy, ROC Curve
  - Precision(정밀도) : 모델에 의해 수행된 모든 긍정적인 예측 중 실제 긍정적인 예측의 비율
    - 장난감 상자에 10번 장난감을 꺼낼 경우, 10번 중에서 장난감 7개와 기타 물건 3개(책, 양말, 연필 등)를 선택함 → 내가 "장난감이다" 라고 집어 든 것들 중에서 진짜 장난감 비율
  - Recall(재현율) : 모든 실제 양성 사례 중 참양성 예측의 비율(남아있는 장난감)
    - 상자에 10개의 장난감이 있다고 상상할 때(더 있을수도 있음), 10개의 장난감 중에서 7개를 찾음 → 리콜은 당신이 발견한 상자 속 장난감의 총 개수에 관한 것 → 상자에 장난감이 총 10개 있었고 그중 7개를 찾았다면 7/10
  - Accuarcy(정확도) : 전체 예측 정답 중 얼마나 올바르게 예측했는가에 대한 비율
  - F1 Score : Precision와 Recall의 조화 평균 → Label의 성능이 불균형일 경우 정확하게 평가할 수 있음

로지스틱 회귀(Logistic Regression)

모델검정

- **Precision(정밀도) :** $\frac{TP}{TP+FP}$
- **Recall(재현율) :** $\frac{TP}{TP+FN}$
- **Accuracy(정확도) :** $\frac{TP+TN}{TP+FN+FP+TN}$
- **F1-Score :** $2\times\frac{Precision\times Recall}{Precision+Recall}$

		실제 정답	
		True(환자)	False(정상)
분류결과	True(환자)	TP(20)	FP(40)
	False(정상)	FN(30)	TN(10)

Precision

Recall

로지스틱 회귀(Logistic Regression)

모델검정

- 높은 Precision, 낮은 Recall → Precision : 내가 잡은 것들 중에 장난감의 비율 → 내선택에서 참의 비율

		실제 정답	
		True(장난감)	False(물건)
분류결과	True(장난감)	TP(5)	FP(0)
	False(물건)	FN(4)	TN(2)

- 높은 Recall, 낮은 Precision → Recall : 상자 안 모든 장난감 중 내가 찾아낸 장난감의 비율 → 참을 얼마나 놓치지 않았나?

		실제 정답	
		True(장난감)	False(물건)
분류결과	True(장난감)	TP(4)	FP(2)
	False(물건)	FN(2)	TN(2)

- 높은 Precision 및 높은 Recall:9개 물건을 집었고 9개 모두 장난감이었고 상자에 장난감이 1개만 남아 있었다면 높은 Precision(장난감만 집은 것)과 높은 Recall(거의 모든 장난감을 찾았음)을 모두 갖게 됨

로지스틱 회귀(Logistic Regression)

모델검정

- ROC(Receiver Operating Characteristic)
- TPR(True Positive Rate) : 실제 클래스 True중에 잘 맞춘 것 → 4/6
- FPR(False Positive Rate) : 실제 클래스 False중에 못 맞춘 것 → 2/4

		실제 정답	
		True(장난감)	False(물건)
분류결과	True(장난감)	TP(4)	FP(2)
	False(물건)	FN(2)	TN(2)

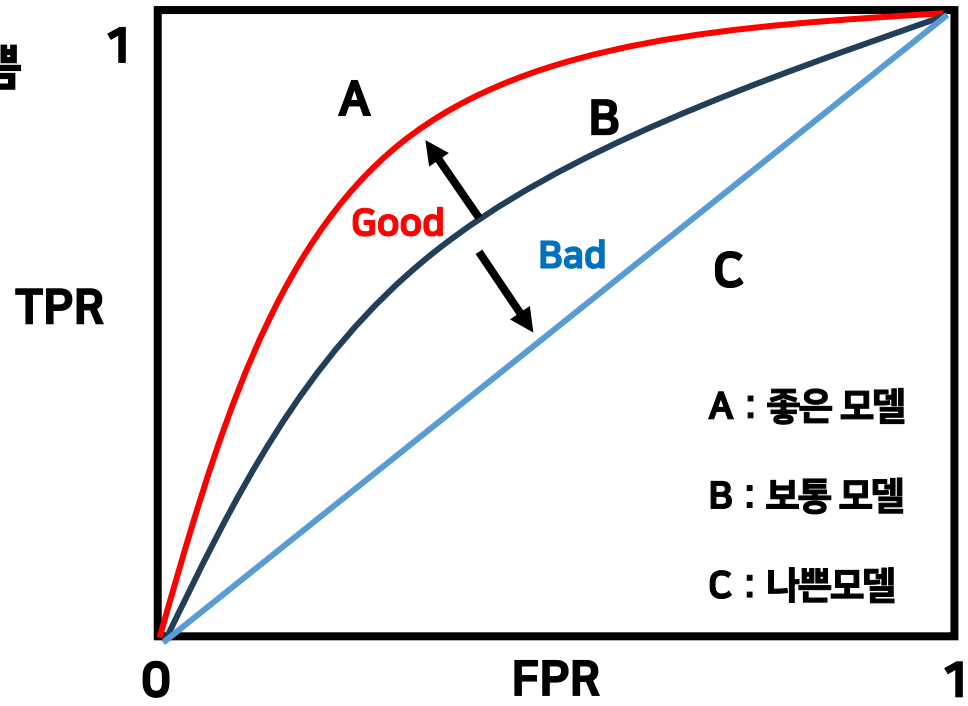
0.5 : 무작위 수준 → 나쁨

0.6~0.7 : 낮음

0.7~0.8 : 보통

0.8~0.9 : 좋음

0.9 이상 : 매우좋음



진짜를 얼마나 놓치지 않고 찾았는가?

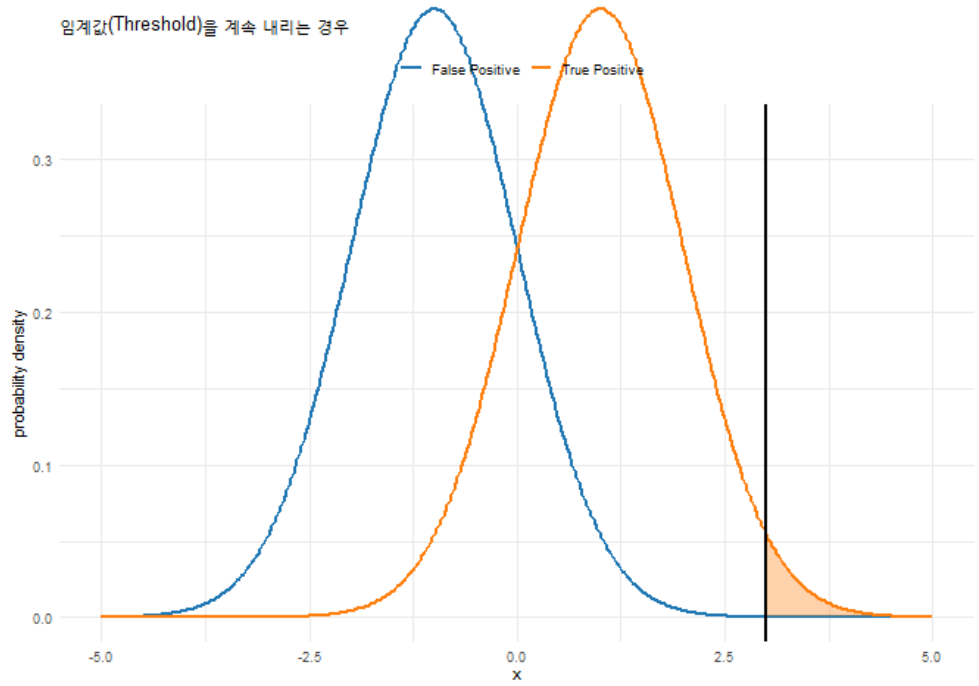
$$TPR = \frac{TP}{TP + FN}$$

가짜를 얼마나 착각했는가?

$$FPR = \frac{FP}{FP + TN}$$

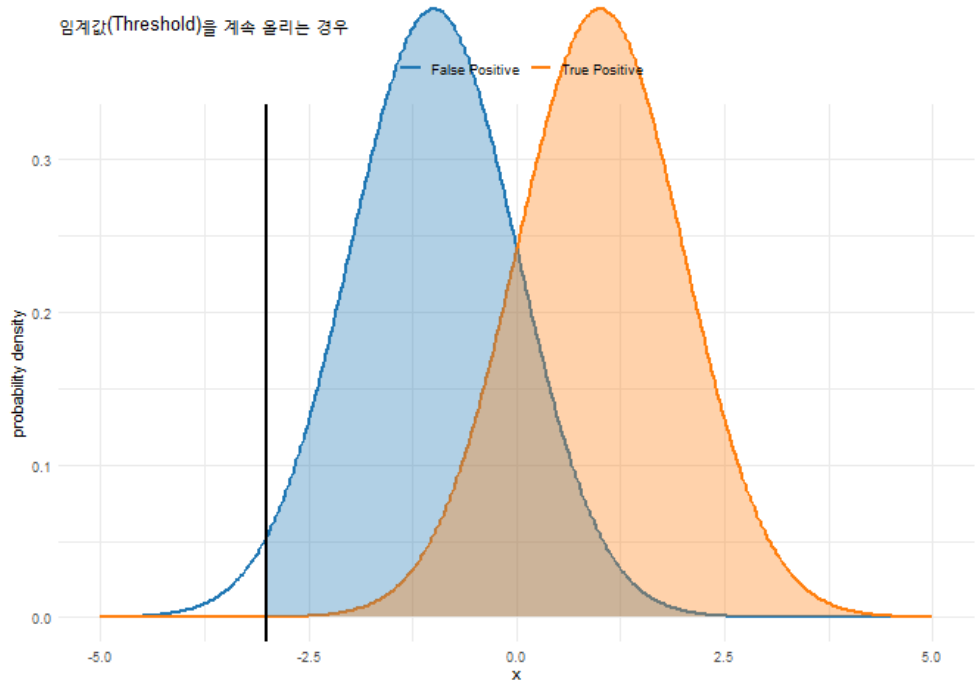
로지스틱 회귀(Logistic Regression)

임계값을 내리는 경우





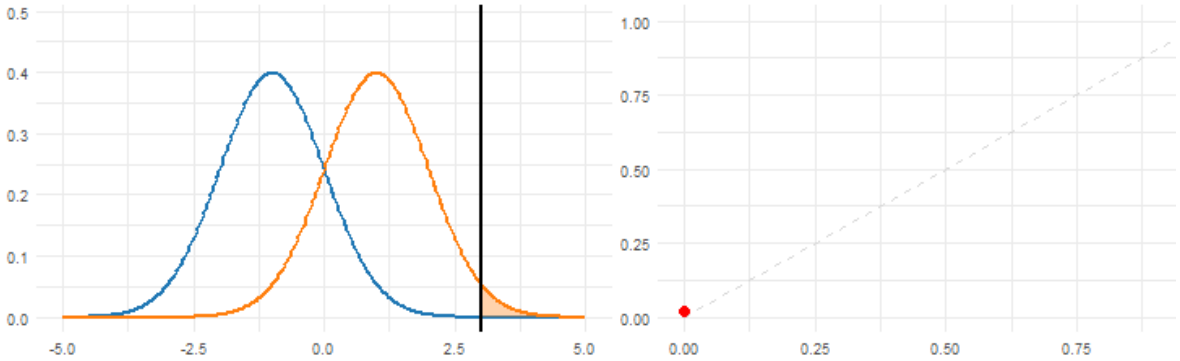
임계값을 올리는 경우

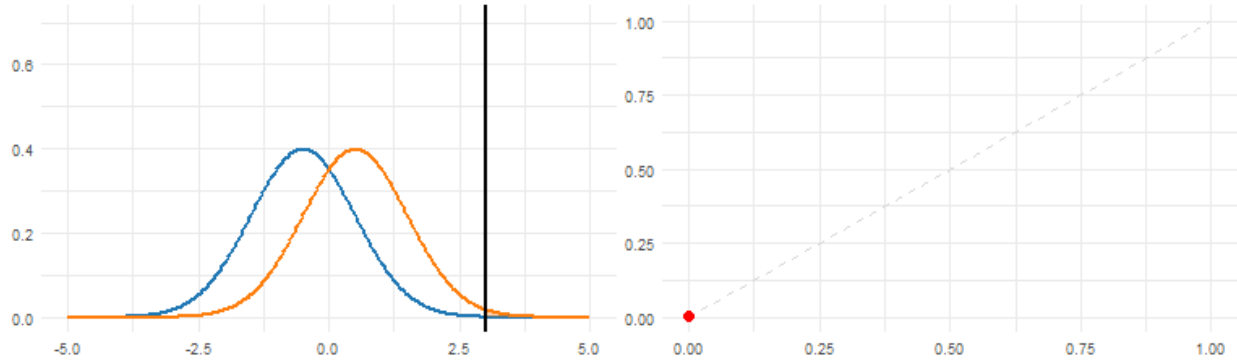




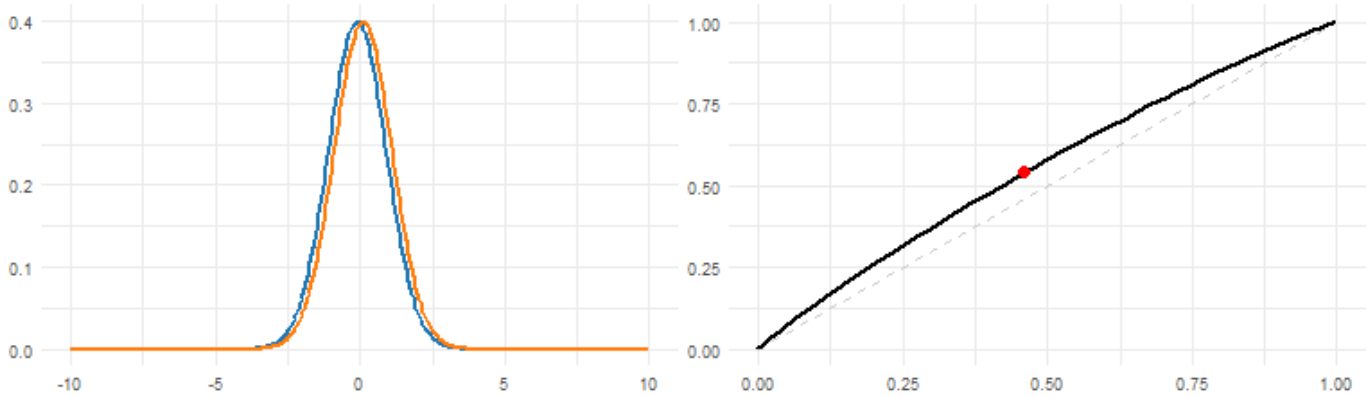
로지스틱 회귀(Logistic Regression)

ROC커브가 그려지는 과정





두 집단의 거리가 멀어질수록 ROC커브가 왼쪽 위로 올라감 → 좋은 결과



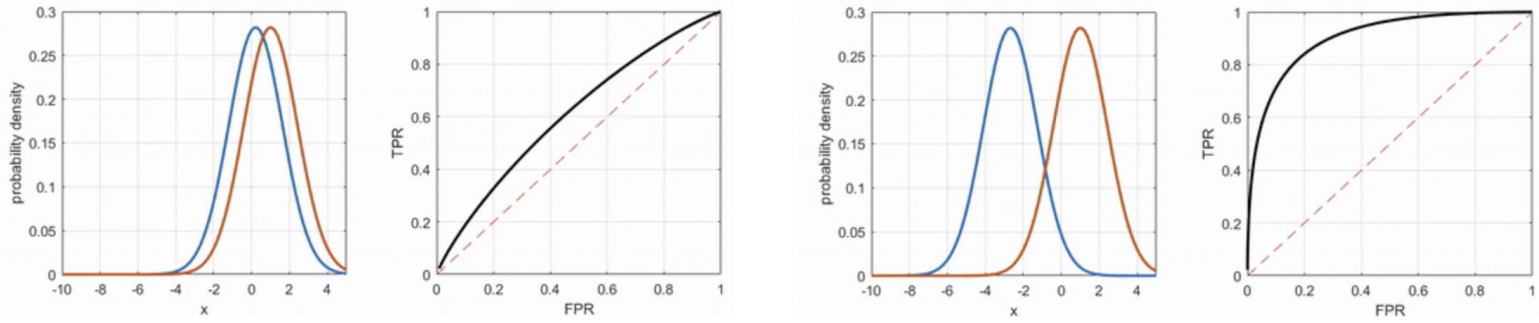
로지스틱 회귀(Logistic Regression)

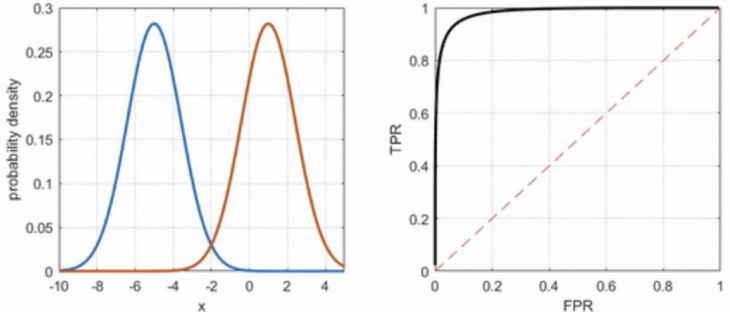
모델검정

- ROC(Receiver Operating Characteristic), AUC(Area Under the Curve)
- TPR(True Positive Rate) : 실제 클래스 True중에 잘 맞춘 것 → 4/6
- FPR(False Positive Rate) : 실제 클래스 False중에 못 맞춘 것 → 2/4

		실제 정답	
		True(장난감)	False(물건)
분류결과	True(장난감)	TP(4)	FP(2)
	False(물건)	FN(2)	TN(2)

$$TPR = \frac{TP}{TP + FN} \qquad FPR = \frac{FP}{FP + TN}$$





로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석(ROC Curve)

```
library(pROC)
library(caret)
library(e1071)

# Test 데이터셋 결과
test_predictions <- predict(result, newdata = test_data, type = "response")
predicted_class <- ifelse(test_predictions > 0.5, "yes", "no")
predicted_class <- as.factor(predicted_class)
print(predicted_class)
```

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석(ROC Curve)

```
# 모델의 Confusion matrix
confusion_matrix <- confusionMatrix(predicted_class, test_data$Personal.Loan)
confusion_matrix

#Mcnemar's Test P-Value(혼동행렬에서 오류가 비대칭인지 파악 : 0.05보다 크면 데이터가 대칭적)
#Kappa(데이터가 한쪽이 너무 많을 때, 한쪽의 값을 도출해도 정확도가 높기 때문에 우연으로 맞췄는지 실제로 맞췄는지를 평가함)
#Kappa값이 1에 가까울 수록 좋은 모델, -값을 가지면 무작위로 예측하는 것 보다 정확도가 낮다는 의미(과적합 판단)

# ROC curve and AUC
roc_curve <- roc(test_data$Personal.Loan, test_predictions)
plot(roc_curve)
auc(roc_curve)
```

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석(ROC Curve)

```
Confusion Matrix and Statistics

          Reference
Prediction  no yes
       no  883  38
       yes  21  58

               Accuracy : 0.941
                 95% CI : (0.9246, 0.9548)
    No Information Rate : 0.904
    P-Value [Acc > NIR] : 1.518e-05

                  Kappa : 0.6309

 Mcnemar's Test P-Value : 0.03725

            Sensitivity : 0.9768
            Specificity : 0.6042
         Pos Pred Value : 0.9587
         Neg Pred Value : 0.7342
             Prevalence : 0.9040
         Detection Rate : 0.8830
   Detection Prevalence : 0.9210
      Balanced Accuracy : 0.7905

       'Positive' Class : no
```

Confusion Matrix(혼동 행렬)

정확도%

데이터가 한쪽이 너무 많을 때, 우연으로 맞췄는지 실제로 맞췄는지를 평가함
Kappa값이 1에 가까울 수록 좋은 모델, -값을 가지면 무작위로 예측하는 것 보다 정확도가 낮다는 의미(과적합 판단)

혼동행렬에서 오류가 비대칭인지 파악 : 0.05보다 크면 데이터가 대칭적

로지스틱 회귀(Logistic Regression)

로지스틱 회귀분석(ROC Curve)

```
# 새로운 데이터를 활용한 모델 적용
df_test <- read.csv("UniversalBank_test.csv", header=TRUE)
```